Hacia un sistema de valuación masiva con BART para la vivienda de Bogotá y alrededores

Towards a BART-based mass appraisal system for housing in Bogotá and its surroundings

Juan Pablo Carrillo Hortua[1,*], **Julian David Rodriguez Ramirez**[1], and **Samuel Acosta Morales**[1]

[1] *Departamento de Matemáticas, Ciencia de Datos, Universidad Externado de Colombia, Bogotá D. C., Colombia*

[*] *juan.carrillo6@est.uexternado.edu.co, julian.rodriguez13@est.uexternado.edu.co, samuel.acosta1@est.uexternado.edu.co*

Docente de Estadística Bayesiana: Jairo Alberto Mora Fernandez, jairo.mora1@uexternado.edu.co

Docente de Pensamiento Crítico: Ghislaine Tibaire Murzi Sifontes, ghislaine.murzi@uexternado.edu.co

Implementar BART para predecir precio de inmuebles

RESUMEN

En Colombia no existe la facilidad para acceder a datos oficiales sobre precios reales de venta de vivienda, y cuando existe, este acceso suele ser poco confiable debido a la subdeclaración fiscal. Bajo este marco, se plantea un prototipo de Sistema de Valuación Masiva (MAS) para la vivienda usada en Bogotá, Soacha, Chía y Zipaquirá, utilizando precios pedidos recolectados mediante *web scraping* del portal FincaRaíz. Como modelo principal se implementa BART(Atr), una adaptación de BART con recorte adaptativo de atípicos propuesta por Cao et al. (2024), el cual se compara mediante validación cruzada contra OLS, Random Forest, XGBoost, LightGBM y un predictor de la mediana. En el conjunto de prueba BART(Atr) obtuvo un MAPE de 16,8 %, un R^2 de 0,809 y un 70,8 % de predicciones dentro del $\pm 20\,\%$, superando con creces lo reportado por Lozano-Gracia and Anselin (2012) para Bogotá y acercándose a XGBoost, que fue el mejor modelo. No obstante, las cadenas MCMC no convergieron ($\hat{R} \approx 1{,}43$), lo cual invalida los intervalos de credibilidad de las predicciones y de los valores SHAP. Por último, el análisis SHAP muestra que el área construida y el estrato son las variables de mayor asociación con el precio, seguidas por características geográficas como la distancia a *landmarks*.

Palabras Clave: Estadística bayesiana; BART; recorte adaptativo de atípicos; valuación masiva de inmuebles; precios pedidos; inteligencia artificial explicable (XAI); valores SHAP; MCMC; Bogotá.

Entrega: 8 de noviembre de 2026.

ABSTRACT

In Colombia, access to official data on actual housing sale prices is limited, and when available, it is usually unreliable due to phenomena such as tax underreporting. Within this framework, a prototype Mass Appraisal System (MAS) is proposed for used housing in Bogotá, Soacha, Chía and Zipaquirá, using asking prices collected through *web scraping* from the FincaRaíz portal. The main model is BART(Atr), an adaptation of BART with adaptive outlier trimming proposed by Cao et al. (2024), which is compared through cross-validation against OLS, Random Forest, XGBoost, LightGBM and a median predictor. On the test set, BART(Atr) achieved a MAPE of 16.8 %, an R^2 of 0.809 and 70.8 % of predictions within $\pm 20\,\%$, widely outperforming the results reported by Lozano-Gracia and Anselin (2012) for Bogotá and approaching XGBoost, which was the best model. However, the MCMC chains did not converge ($\hat{R} \approx 1{,}43$), which invalidates the credible intervals for both the predictions and the SHAP values. Finally, the SHAP analysis shows that built area and socioeconomic stratum are the variables most strongly associated with price, followed by geographic features such as distance to *landmarks*.

Keywords: Bayesian statistics; BART; adaptive trimming; mass appraisal; asking prices; explainable artificial intelligence (XAI); SHAP values; MCMC; Bogotá.

1. Introducción

Actualmente, en Colombia no existe la facilidad para acceder a datos oficiales sobre precios reales de venta de viviendas por parte del Estado, y cuando existe acceso, este por lo general es poco confiable debido a fenómenos como la subdeclaración fiscal Lozano-Gracia and Anselin (2012). Como señala Iban (2022), esta falta de información transaccional no es exclusiva del contexto colombiano y se replica en otros países en desarrollo como Turquía, de ahí que nazca el interés en el desarrollo de Sistemas de Valuación Masiva (MAS) utilizando precios ofrecidos (asking prices) recopilados a

partir de portales web como FincaRaíz.

Los sistemas de valuación masiva en FincaRaíz son una forma que se suele utilizar en países con información inmobiliaria disponible para estimar mejor los precios; asimismo, estos sistemas tienen un efecto regulatorio en el comportamiento del mercado y permiten pasar de valuaciones subjetivas hechas por valuadores humanos que difieren entre sí Lozano-Gracia and Anselin (2012); Iban (2022); Tapia et al. (2025). No obstante, en países con poco acceso a información sobre ventas reales, la creación de estos sistemas se complica sustancialmente Lozano-Gracia and Anselin (2012); Iban (2022). Bajo este marco, se plantea la pregunta de investigación:

¿Qué factores de ubicación (localidad/municipio, estrato) y de características físicas (área, habitaciones, baños, antigüedad) se asocian con el precio pedido de la vivienda usada en Bogotá, Soacha, Chía y Zipaquirá y cuáles son los mejores para predecir el precio?

1.1 Objetivos

1.1.1 Objetivo General

Crear un prototipo de un sistema **MAS** para los precios pedidos en Bogotá y alrededores, esto con el fin generar una forma sistemática de valuar los precios de manera sistemática, así contribuyendo a la estabilización del mercado inmobiliario de la ciudad.

1.1.2 Objetivos Específicos

- Obtener métricas mejores o similares a las reportadas anteriormente en la literatura; específicamente, se plantea superar las mejores métricas reportadas por Lozano-Gracia and Anselin (2012) para Bogotá, independientemente de que pertenezcan al mismo modelo (MAPE = 29.99 %, Porcentaje Mediano de Sobrepredicción = 60.59 %, Porcentaje de Predicciones dentro del Margen del $\pm 10\,\%$ = 17.06 %).
- Implementar métodos XAI con el fin de explicar cómo influyen las variables en la predicción del modelo, de esta manera dando un modelo con una alta explicabilidad Iban (2022).
- Generar cadenas por el método de MCMC que converjan de manera satisfactoria; esto con el fin de aportar intervalos de credibilidad bayesianos a las predicciones y a los valores de métodos XAI como SHAP.

2. Revisión de la literatura

2.1 Fundamentos teóricos del mercado residencial y el precio del suelo

El mercado residencial se distancia de la teoría económica tradicional, ya que viola el supuesto de homogeneidad y divisibilidad de los bienes; o, en otras palabras, que un bien con las mismas características puede variar su precio según dónde se localice y que no se puede comprar una vivienda por partes (ejemplo: solo tomar el baño de un inmueble). Como es sintetizado por Chang (2006), la localización es un factor heterogéneo e indivisible que se ve influido por factores como las conexiones de transporte, la calidad de los servicios públicos y las características del entorno. Un modelo común en la literatura son modelos de subasta de ofertas; sin embargo, esta clase de modelo presenta varias trabas operativas en la práctica, entre ellas la necesidad de poseer un volumen masivo de datos y generar una formulación matemática compleja que no da un modelo predictivo directo.

2.2 Antecedentes

En el contexto del mercado de vivienda usada en Bogotá, Soacha, Chía y Zipaquirá, la ausencia de un conocimiento cuantitativo sistematizado genera el riesgo de que los asesores inmobiliarios fijen los precios pedidos con base en criterios informales o consultas entre colegas, tal como señala la Tapia et al. (2025) para el mercado chileno. Esta práctica genera una dispersión relevante del precio por metro cuadrado entre inmuebles comparables. Por esta razón, el proyecto no intenta calibrar un modelo complejo de equilibrio general ni de subasta teórica, sino que adopta propuestas de modelo usadas previamente por Iban (2022); Lozano-Gracia and Anselin (2012); Cao et al. (2024); asimismo, utilizando variables que ya se han probado tienen un impacto en el precio de los inmuebles, tales como tener centros comerciales cercanos Villada-Medina et al. (2023), parques cercanos Loret de Mola et al. (2017) o características propias del inmueble.

Ante la falta de datos oficiales y masivos, se han planteado varias soluciones; una de ellas es la de Iban (2022), que recolectó precios pedidos estimados por agentes inmobiliarios independientes. Por otro lado, debido a que en Bogotá no existía un registro abierto y transparente de transacciones reales de compraventa y los precios declarados solían sufrir de subdeclaración fiscal para evitar impuestos, Lozano-Gracia and Anselin (2012) recolectó datos de catastro tomados con dos metodologías diferentes:

1. **Censo de oferta de venta:** A través del programa del *Observatorio Inmobiliario* iniciado en 2002, registra-

ron de forma censal las propiedades puestas en venta anunciadas en letreros de las viviendas y periódicos locales. Esto es similar a la metodología que plantea este proyecto más adelante, solo que en esta oportunidad la recolección se hará mediante *web scraping*.

2. **Llamadas y negociación simulada (*Mystery Shopping*):** Funcionarios de la oficina de Catastro llamaban por teléfono a los propietarios haciéndose pasar por compradores potenciales interesados en pagar en efectivo.

Luego, esa información recolectada sobre los precios se conectó con las características de los inmuebles utilizando la ficha predial conectada a las bases de datos físicas e históricas del Catastro Distrital. Esto deja ver claramente que, en mercados en los que los datos oficiales faltan o son poco confiables, lo usual es trabajar con precios pedidos (aunque posiblemente estos estén sesgados); de ahí que se decida utilizar un *scraping*. No obstante, esto también implica riesgos similares a los que reporta Iban (2022) derivados del uso de este muestreo no probabilístico por conveniencia, pues se señala que los datos recopilados por estas vías presentan baja fiabilidad de origen e imprecisiones que impiden medir el riesgo respecto al universo total de transacciones y restringen la generalización del modelo, lo cual se verá más adelante al denotar que la muestra tiene una mayor representatividad de ciertos sectores de la ciudad.

En Bogotá, Lozano-Gracia and Anselin (2012) ya ha implementado un intento de un sistema de valuación masiva utilizando conjuntos de modelos OLS independientes para cada submercado; dichos modelos presentan un rendimiento modesto, pero aportan una línea base contra la cual comparar el rendimiento del modelo planteado y, adicionalmente, constata la importancia del estrato como factor de apreciación de los inmuebles. En Turquía, Iban (2022) implementó modelos de ensamble de árboles como **Random Forest, Gradient Boosting, XGBoost o LightGBM**. Tales modelos obtuvieron métricas excepcionales; sin embargo, cabe mencionar que solo se tomó en consideración un distrito de Mersin, Turquía, lo cual puede llegar a simplificar el problema que el modelo aprende.

Las metodologías de Inteligencia Artificial Explicable (XAI/IML), y en particular el cálculo de valores SHAP (*SHapley Additive exPlanations*) como los usados por Iban (2022), permiten abrir la denominada «caja negra» de los modelos predictivos avanzados para transparentar la contribución y el peso relativo de cada variable en la estimación del valor. Sin embargo, la literatura destaca algunos riesgos en el uso de herramientas SHAP; uno de ellos es que, si se interpretan los valores SHAP ignorando la autocorrelación espacial (el grado en que las observaciones de una misma variable están correlacionadas entre sí en función de la ubicación geográfica de los datos), se puede incurrir en la identificación de relaciones espurias entre las *features* y la variable objetivo (*target*).

Para el desarrollo del estimador cuantitativo en Bogotá, Soacha, Chía y Zipaquirá, esta distinción fundamenta la decisión de asumir que la correlación no implica causalidad. Por ello, los modelos de *Machine Learning* y las explicaciones SHAP se utilizarán para ofrecer una lectura transparente y desagregada de cómo se conforma el precio pedido para cada vivienda usada, evitando utilizar las explicaciones como deducciones causales directas sobre el precio pedido.

2.3 Aporte que se busca realizar

En este trabajo se plantea una adaptación del método de recorte adaptativo de atípicos (*Adaptive Trimming*) desarrollado por Cao et al. (2024). Dado que este algoritmo es reciente y únicamente ha sido evaluado en conjuntos de datos sintéticos y en el tradicional dataset restringido de Boston, este estudio busca evaluar su viabilidad en un mercado masivo, denso y expuesto a ruido real como el de Bogotá y sus municipios aledaños. Asimismo, la arquitectura bayesiana de BART permite obtener intervalos de credibilidad predictiva que superan las estimaciones puramente puntuales de los modelos deterministas tradicionales, ofreciendo una cuantificación rigurosa de la incertidumbre asociada a la valoración de cada propiedad.

Adicionalmente, el proyecto incorpora una capa de Inteligencia Artificial Explicable (XAI) mediante el cálculo de valores SHAP (*SHapley Additive exPlanations*), siguiendo los esquemas de interpretación global y local validados por Iban (2022). Esta integración permite mitigar la naturaleza de caja negra inherente a los modelos de ensamble no lineales basados en árboles, descomponiendo la contribución marginal exacta de las variables estructurales, locacionales y urbanas sobre el precio. De este modo, se combina la alta precisión predictiva con una interpretabilidad cuantitativa transparente y defendible.

3. Metodología

3.0.1 Población

La población de interés consta de todas las viviendas de Bogotá y alrededores (Chía, Zipaquirá y Soacha); específicamente, la muestra recolectada abarca: casas, apartamentos, apartaestudios, fincas y casas campestres, todas ellas extraídas del portal de datos **FincaRaiz.com mediante un scraper** creado con la asistencia de inteligencia artificial. No obstante, es necesario recalcar que la muestra extraída tiene una

mayor representatividad por parte de inmuebles ubicados en la zona norte de la ciudad, lo cual podría constituir cierto sesgo, ya sea en el análisis descriptivo y representatividad de la población.

3.0.2 Diccionario de datos

La tabla 1 describe las variables del conjunto de datos extraído de FincaRaíz. Las variables marcadas con † no provienen directamente del portal, sino que fueron construidas a partir de las coordenadas de cada inmueble.

3.0.3 Procesamiento

La base de datos que se sustrajo de Fincaraiz.com presentaba serias inconsistencias de datos, principalmente provenientes de inconsistencias en cómo el portal maneja la información de entidades especiales, como proyectos que están en construcción, o también provenientes de errores de digitación por parte de los vendedores. Adicionalmente, se limitó la base de datos para responder solo a las preguntas sobre la vivienda y se eliminaron columnas inútiles para el propósito del proyecto[1]. A continuación, se expone paso a paso el procesamiento por el cual pasó la base, especialmente su limpieza (el preprocesamiento para modelos se abarcará en secciones posteriores).

Eliminar columnas inútiles para el propósito del proyecto Las siguientes columnas se eliminaron, ya que no aportan ninguna clase de información útil para el proyecto; la siguiente tabla presenta dichas columnas y el motivo de su eliminación.

Eliminar propiedades comerciales Ya que el proyecto se enfoca en el análisis de la vivienda en Bogotá y alrededores, esta clase de propiedades solo agregarían ruido en el análisis; por lo tanto, se eliminan. Esto supuso una reducción del 26,87 % en el tamaño del conjunto de datos; sin embargo, no se considera una pérdida de información, puesto que desde un inicio no eran sujetos de interés.

Verificar la consistencia de las coordenadas Se generaron una serie de *bounding boxes* basadas en datos geográficos para ratificar que los inmuebles reportaran coordenadas dentro de Cundinamarca, que las coordenadas coincidieran con la localidad que reportaba la columna `locality` y, por último, que el precio del inmueble no fuese atípico respecto a los demás inmuebles de su localidad. Cabe resaltar que se tiene tan alta confianza en esas coordenadas recolectadas, ya que se toman directamente del servicio de mapas que implementa el portal, además de no presentar ninguna clase de valor faltante. Exactamente, se identificaron alrededor de 473 viviendas atípicas; esto supone un 2 % de la muestra; por esto mismo, se opta por su eliminación. Además, se eliminaron 100 inmuebles cuyas coordenadas estaban fuera de Cundinamarca.

Imputar valores faltantes Posiblemente, esta es la parte más crítica del procesamiento, esto debido a que la base contenía una cantidad considerable de nulos, como se muestra en el siguiente gráfico.

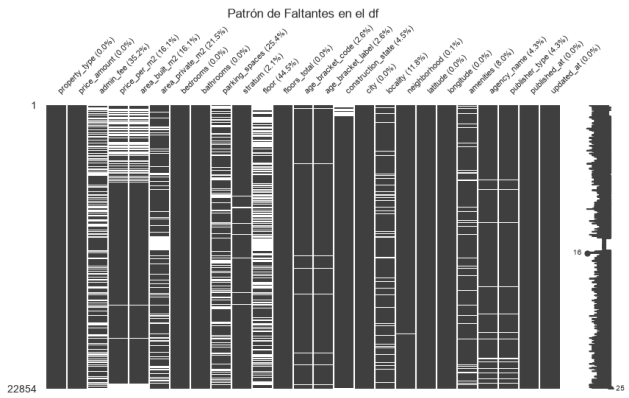


Fig. 1. Distribución de valores faltantes en la base de datos.

La mayor proporción de datos faltantes se presenta en `floor` (44,3 %), seguida por `admin_fee` y `parking_spaces`. Una variable que recogió el *scraper* se llamaba `floors_total` y tenía un porcentaje de 71 % de nulos; sin embargo, no se reporta, ya que se optó posteriormente por su eliminación. Esto se debe a que, por lo general, un nulo equivalía a viviendas de un piso o que no lo reportaban; sin embargo, dicha propiedad era altamente inconsistente, razón por la cual se optó por su eliminación.

Los nulos que ya se mostraron se trataron con diferentes técnicas, entre ellas MICE, una imputación basada en coordenadas (la localidad se rellenaba usando las *bounding boxes* mencionadas anteriormente), la moda, KNNImputer y unas reglas de negocio; estas reglas se usaron en 2 columnas: el nombre de la agencia y el tipo de publicador. La regla se ba-

[1] Para más detalles del proceso de limpieza, consulte en el repositorio `notebooks/data_cleaning.ipynb`, `notebooks/data_preparation.ipynb` y `notebooks/BART_Trees.ipynb`.

Variable	Unidad	Descripción
Identificación y operación		
`listing_id`	id	Identificador único del anuncio en FincaRaíz.
`operation`	categoría	Tipo de transacción anunciada: `venta` o `arriendo`.
`property_type`	categoría	Tipo de inmueble: `apartamento`, `casa`, `oficina`, `bodega`, `local`, `lote`, entre otros.
Precio y costos		
`price_amount`	COP	Precio pedido publicado en el anuncio.
`price_currency`	categoría	Moneda en la que se expresa el precio pedido.
`admin_fee`	COP/mes	Cuota mensual de administración del inmueble.
`total_monthly_cost`	COP/mes	Canon de arriendo más administración; definido solo para anuncios de arriendo.
`price_per_m2`	COP/m^2	Precio pedido dividido entre el área construida.
Características físicas		
`area_built_m2`	m^2	Área construida del inmueble.
`area_private_m2`	m^2	Área privada interior de la unidad.
`bedrooms`	conteo	Número de habitaciones.
`bathrooms`	conteo	Número de baños.
`parking_spaces`	conteo	Número de parqueaderos incluidos con el inmueble.
`floor`	número de piso	Piso del edificio en el que se ubica la unidad.
`floors_total`	conteo	Número total de pisos del edificio.
`age_bracket_code`	ordinal 0–5	Antigüedad del inmueble por rangos: 0 = a estrenar, 1 = menos de 1 año, 2 = 1–8 años, 3 = 9–15 años, 4 = 16–30 años, 5 = más de 30 años.
`age_bracket_label`	categoría	Etiqueta en texto (español) del rango de antigüedad.
`construction_state`	categoría	Estado declarado en el anuncio: `Usado`, `Excelente estado`, `En construcción`, entre otros.
`amenities`	lista (sep. por |)	Amenidades y características atribuidas al inmueble o a su edificio.
Ubicación		
`stratum`	ordinal 1–6	Estrato socioeconómico asignado a la dirección.
`city`	nombre	Municipio en el que se ubica el inmueble.
`locality`	categoría	Localidad de Bogotá que contiene el inmueble.
`neighborhood`	nombre	Barrio del inmueble.
`address_text`	texto	Dirección tal como aparece publicada en el anuncio.
`latitude`	grados (WGS84)	Latitud de la ubicación del inmueble en el mapa.
`longitude`	grados (WGS84)	Longitud de la ubicación del inmueble en el mapa.
`dist_nearest_positive_km`†	km	Distancia desde el inmueble hasta el *landmark* positivo más cercano, es decir, un punto de referencia que se espera aumente el precio. Calculada a partir de `latitude` y `longitude`.
`dist_nearest_negative_km`†	km	Distancia desde el inmueble hasta el *landmark* negativo más cercano, es decir, un punto de referencia que se espera disminuya el precio. Calculada a partir de `latitude` y `longitude`.
Publicación		
`agency_name`	nombre	Inmobiliaria que publica el anuncio.
`publisher_type`	categoría	Tipo de anunciante: `inmobiliaria` o `desarrollador`.
`published_at`	fecha (AAAA-MM-DD)	Fecha de la primera publicación del anuncio.
`updated_at`	fecha (AAAA-MM-DD)	Fecha de la última actualización del anuncio.
`source_url`	URL	Dirección web del anuncio.

Tabla. 1. Diccionario de datos

Variable	Tipo de problema	Razón de la eliminación
`listing_id`	Identificador	Es un código asignado por el portal a cada anuncio; no describe ninguna característica del inmueble y su inclusión solo permitiría al modelo aprender patrones espurios.
`operation`	Varianza nula	Al restringir la muestra a inmuebles en venta, la variable toma un único valor (`venta`) para todas las observaciones, por lo que no aporta información al modelo.
`source_url`	Identificador	Es la dirección web del anuncio; al igual que `listing_id`, es única para cada observación y no contiene información sobre el precio.
`total_monthly_cost`	No aplica / valores faltantes	Corresponde a viviendas en arriendo, por lo que solo está definida para anuncios de arriendo; en la muestra de ventas es completamente faltante.
`address_text`	Texto libre / redundante	Es texto no estructurado con formatos inconsistentes entre anuncios. La información de ubicación que contiene ya está capturada de forma estructurada en `latitude`, `longitude`, `neighborhood` y `locality`.

Tabla. 2. Variables eliminadas y motivo de su exclusión

saba en que `agency_name`[2] y `publisher_type` presentan un patrón 1:1 en sus valores faltantes, por lo que se infiere que estos registros corresponden a ventas directas realizadas sin intermediación de una agencia. Por esto mismo, se llenaron con **Sin Agencia** y **Particular**, respectivamente. El siguiente gráfico resume el tratamiento de valores nulos junto al porcentaje de relleno.

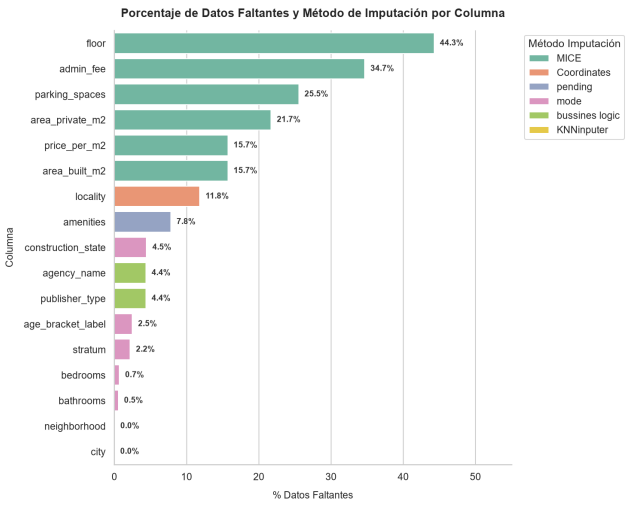


Fig. 2. Resumen del tratamiento de valores nulos y porcentaje de relleno.

Cabe resaltar que las columnas que se imputaron con MICE presentan un comportamiento de tipo MAR (*Missing at Random*) en sus valores faltantes, lo cual sustenta esta metodología de imputación. El patrón MAR fue probado mediante pruebas de hipótesis de Chi-cuadrado para variables categóricas y de U de Mann-Whitney para variables continuas.

Manejo de atípicos inicial Primero, se aplicaron reglas más amplias para tratar los valores atípicos superiores, debido a la escala extrema que presentan algunas variables. Si se utilizara directamente el criterio de $1,5 \times$ IQR, el límite inferior podría quedar por debajo de 0, por lo que la limpieza no sería adecuada para variables que no admiten valores negativos.

Dicho lo anterior, se definió la limpieza inicial[3] de atípicos en tres etapas diferentes: reglas de negocio para el precio pedido (`price_amount`), reglas de negocio para el área construida y privada (`area_built_m2` y `area_private_m2`, respectivamente) y, por último, un criterio utilizando el IQR (en este caso $3 \times$ IQR para evitar eliminar inmuebles de lujo). Las reglas de negocio se exponen en la tabla 3.

Después de realizar esta limpieza de atípicos, se da por concluida la limpieza del conjunto de datos. En el siguiente gráfico se expone cómo evolucionó el tamaño del conjunto a lo largo del proceso.

[2]Esta columna se eliminó, ya que se consideró que podría llevar a relaciones espurias, pues el modelo podría predecir los precios basándose en que la agencia vende cierto tipo de propiedades, en lugar de usar las características.

[3]Es inicial, ya que BART (Árboles) implementa de manera nativa el manejo de valores atípicos.

Variable	Rango conservado	Justificación
`price_amount`	Entre \$30 millones y \$20.000 millones COP	Se identificaron precios extremadamente bajos y un precio superior a \$20.000 millones, que no resultan consistentes con las características observadas de los inmuebles.
`area_built_m2` `area_private_m2`	Mayor que 10 m^2 y menor que 5.000 m^2	Áreas menores o iguales a 10 m^2 o mayores o iguales a 5.000 m^2 no son plausibles para una vivienda y se consideran atípicos de negocio.

Tabla. 3. Valores atípicos de negocio y criterios de exclusión

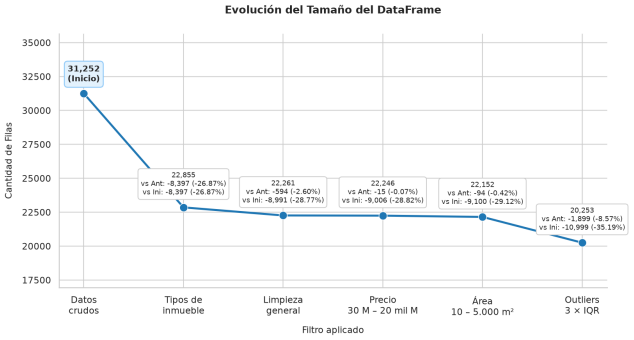


Fig. 3. Evolución del tamaño del conjunto de datos a lo largo del proceso. **Limpieza general:** precios en USD, estrato inválido, `cabana`, precio 0, precios atípicos por localidad, fuera de Cundinamarca y sin localidad.

Todo el proceso redujo el tamaño de la base de datos en un 35,19 %; sin embargo, recuerde que el primer paso de reducción constituye una delimitación de objetivos; de ahí en adelante, la reducción de tamaño por motivos de calidad supone una reducción baja en la información, específicamente de un $\approx 11{,}38\,\%$.

Creación de características Adicionalmente, se crean 5 nuevas variables basadas en la literatura; estas se derivan de 2 fuentes diferentes: 3 de ellas vienen de la lista de amenidades recolectada en el portal web y otras dos provienen del cálculo de distancias respecto a unos puntos clave de la universidad.

Los *landmarks* positivos en su mayoría se asocian con puntos como parques y centros comerciales, tal como se ha hecho en los antecedentes presentados, y los *landmarks* negativos se asocian mayoritariamente con construcciones industriales como plantas de tratamiento de agua, cementerios, zonas de tolerancia y cárceles. Estos *landmarks* se distribuyen de tal modo que localidades más pequeñas (como Rafael Uribe Uribe o Antonio Nariño) tienen 2 *landmarks* positivos y 2 negativos, mientras que localidades de mayor tamaño como Suba y Usaquén tienen 4 y 4. Los *landmarks* se muestran en el siguiente mapa.

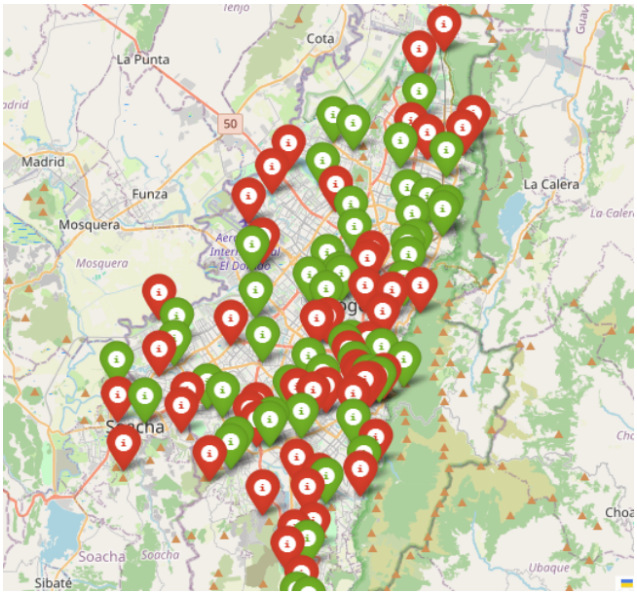


Fig. 4. Distribución de *landmarks* positivos y negativos en las localidades.

Codificación de categorías Las categorías nominales con baja cardinalidad (`construction_state`, `city`, `publisher_type` y `property_type`) se codificaron usando *One-Hot encoding*, mientras que las de alta cardinalidad y nominales (`locality` y `neighborhood`) se codificaron utilizando *Frequency encoding*.

Conjunto final características

3.0.4 Hipótesis

Con base en la literatura consultada y a los datos extraídos, se plantean las siguientes hipótesis para esta investigación:

1. **Dimensión física y atributos intrínsecos del inmueble:** A medida que se incrementa la escala física de la vivienda (medida a través del área construida, el número de baños, la cantidad de dormitorios y las demás

Variable	**Derivada de**	**Qué representa**
Trans Publico cerc	Amenidades	Es una variable binaria que representa si se reportó que el inmueble posee transporte público cerca, esto basado en lo encontrado por Iban (2022); Tapia et al. (2025).
Zona Residencial	Amenidades	Es una variable binaria que representa si se reportó que la propiedad estaba en una zona residencial, tal como lo plantea Lozano-Gracia and Anselin (2012) con sus variables sobre el uso del suelo, solo que esta variable que se creó no se basa en datos de catastro; en su lugar, se basa en la percepción que se podría tener de la zona.
n_amenities	Amenidades	Es el conteo de cuántas amenidades diferentes se reportaron; se basa en el hecho de que la literatura menciona reiteradamente la importancia de tener amenidades cercanas y se plantea esta variable como *proxy* del grado de comodidad de la zona.
dist_nearest_positive_km	Landmarks	Se define como la distancia al *landmark* positivo (es decir, que aporta plusvalía) más cercano, esto sustentado por lo que demostró Tapia et al. (2025) en relación a la cercanía a parques, la cual se asocia con una fuerte explicación de la variabilidad de los precios y también se sustenta según Villada-Medina et al. (2023) en Medellín, donde tener centros comerciales cerca (en un radio de 0,5 km) incrementa el precio de la vivienda entre un 3,59 % y un 7,39 %.
dist_nearest_negative_km	Landmarks	Se define como la distancia al *landmark* negativo más cercano, esto sustentado por lo definido por Lozano-Gracia and Anselin (2012) respecto a la cercanía a lugares como botaderos, sectores de estrato 1 y demás factores.

Tabla. 4. Descripción de las variables derivadas de amenidades y puntos de interés (*landmarks*).

Variable	Tipo / unidad	Descripción
Características físicas		
`area_built_m2`	m^2	Área construida del inmueble. Se conserva en lugar de `area_private_m2`, que se eliminó por multicolinealidad (VIF).
`bedrooms`	conteo	Número de habitaciones.
`bathrooms`	conteo	Número de baños.
`parking_spaces`	conteo	Número de parqueaderos incluidos con el inmueble.
`floor`	número de piso	Piso del edificio en el que se ubica la unidad.
`age_bracket_code`	ordinal 0–5	Antigüedad por rangos: 0 = a estrenar, 1 = menos de 1 año, 2 = 1–8 años, 3 = 9–15 años, 4 = 16–30 años, 5 = más de 30 años.
`construction_state_grouped_A estrenar`	binaria (0/1)	1 si el estado declarado es «A estrenar». Categoría base: «Usado».
`construction_state_grouped_Buen estado`	binaria (0/1)	1 si el estado declarado es «Buen estado».
`construction_state_grouped_Excelente estado`	binaria (0/1)	1 si el estado declarado es «Excelente estado».
`construction_state_grouped_Otros`	binaria (0/1)	1 si el estado declarado no está entre los cuatro más frecuentes.
Tipo de inmueble		
`property_type_apartaestudio`	binaria (0/1)	1 si el inmueble es un apartaestudio. Categoría base: apartamento.
`property_type_casa`	binaria (0/1)	1 si el inmueble es una casa.
`property_type_casa_campestre`	binaria (0/1)	1 si el inmueble es una casa campestre.
`property_type_finca`	binaria (0/1)	1 si el inmueble es una finca.
`property_type_habitacion`	binaria (0/1)	1 si el inmueble es una habitación.
Ubicación		
`stratum`	ordinal 1–6	Estrato socioeconómico asignado a la dirección.
`latitude`	grados (WGS84)	Latitud de la ubicación del inmueble.
`longitude`	grados (WGS84)	Longitud de la ubicación del inmueble.
`city_Chía`	binaria (0/1)	1 si el inmueble está en Chía. Categoría base: Bogotá.
`city_Soacha`	binaria (0/1)	1 si el inmueble está en Soacha.
`city_Zipaquirá`	binaria (0/1)	1 si el inmueble está en Zipaquirá.
`locality_frec`	frecuencia	Codificación por frecuencia de la localidad: número de veces que aparece la localidad del inmueble en la muestra.
`neighborhood_grouped_frec`	frecuencia	Codificación por frecuencia del barrio. Los barrios fuera de los 20 más comunes se agrupan en «Otros».
`dist_nearest_positive_km`	km	Distancia desde el inmueble hasta el *landmark* positivo más cercano, es decir, un punto de referencia que se espera aumente el precio.
`dist_nearest_negative_km`	km	Distancia desde el inmueble hasta el *landmark* negativo más cercano, es decir, un punto de referencia que se espera disminuya el precio.
Amenidades		
`Trans Publico cerc`	binaria (0/1)	1 si entre las amenidades del anuncio figura transporte público cercano.
`Zona Residencial`	binaria (0/1)	1 si entre las amenidades del anuncio figura ubicación en zona residencial.
`n_amenities`	conteo	Número total de amenidades listadas en el anuncio.
Costos y publicación		
`admin_fee`	COP/mes	Cuota mensual de administración.
`publisher_type_desarrollador`	binaria (0/1)	1 si el anuncio lo publica un desarrollador. Categoría base: particular.
`publisher_type_inmobiliaria`	binaria (0/1)	1 si el anuncio lo publica una inmobiliaria.
`meses_ofertado`	meses	Meses transcurridos entre la fecha de publicación (`published_at`) y agosto de 2026.

Tabla. 5. Diccionario de las variables explicativas finales (32 variables)

características físicas listadas), el precio pedido total de la propiedad aumenta de, siendo la superficie construida el atributo estructural con mayor capacidad explicativa sobre el valor del inmueble Lozano-Gracia and Anselin (2012); Iban (2022); Villada-Medina et al. (2023); Tapia et al. (2025).

2. **Localización por zonas de alto valor:** La ubicación geográfica en sectores del norte y oriente urbano (como las localidades de Usaquén y Chapinero en Bogotá) ejerce un impacto positivo sobre el precio pedido por metro cuadrado Lozano-Gracia and Anselin (2012); Loret de Mola et al. (2017); Tapia et al. (2025).

3. **Proximidad a amenidades y desamenidades urbanas (*landmarks*):** La localización respecto a infraestructuras del entorno condiciona el valor del inmueble de forma considerable; mientras que la cercanía a amenidades positivas, tales como centros comerciales Villada-Medina et al. (2023) y parques o espacios verdes Loret de Mola et al. (2017); Tapia et al. (2025), genera un incremento en el precio por metro cuadrado, la lejanía física respecto a *landmarks* negativos o externalidades desfavorables (como el relleno sanitario Doña Juana, zonas industriales o centros penitenciarios) impacta positivamente la valoración de la vivienda al reducir el efecto desvalorizador de dichas fuentes de congestión, contaminación o deterioro Lozano-Gracia and Anselin (2012); Tapia et al. (2025).

4. **Accesibilidad a transporte público:** La proximidad a estaciones de transporte público constituye un factor determinante en el valor del inmueble Chang (2006); Tapia et al. (2025).

5. **Estrato socioeconómico:** Las viviendas localizadas en estratos socioeconómicos superiores presentan sistemáticamente un precio más elevado, actuando el estrato como una variable clave en el mercado inmobiliario colombiano Lozano-Gracia and Anselin (2012).

3.0.5 Modelo propuesto

Como modelo principal, se propone el uso del modelo BART(Atr) propuesto por Cao et al. (2024), esto ya que la implementación del proceso de trimming o recorte de atípicos basado en los residuos del modelo es realmente útil para el contexto de estimación de precios de viviendas (una variable naturalmente asimétrica). Asimismo, al basarse en un enfoque bayesiano, aporta dos ventajas clave: la primera es que sus predicciones están ligadas a un intervalo de credibilidad que permite estimar la confianza sobre ellas; bajo esta misma línea, los gráficos relacionados a SHAP también adquieren la posibilidad de ser estimados con intervalos de credibilidad. Sin embargo, estas dos ventajas están ligadas a la convergencia de la cadena de Markov.

A continuación, se ahonda más en el funcionamiento de BART(Atr):

Paso 1. Entrenar el modelo: Se entrena el modelo BART inicial $f(x_i)$ para obtener las predicciones $\hat{y}_i = \hat{f}(x_i)$.

Paso 2. Calcular residuos: Se obtienen los residuos $\hat{\varepsilon}_i = y_i - \hat{y}_i$ y se ordenan por su valor absoluto de menor a mayor:

$$|\hat{\varepsilon}|_{(1)} \leq |\hat{\varepsilon}|_{(2)} \leq \cdots \leq |\hat{\varepsilon}|_{(n)}$$

Paso 3. Estimar la varianza de los residuos con el 25 % menor y corregir la escala de σ usando la distribución teórica: Se calcula la estimación robusta $\hat{\sigma}^2$ utilizando únicamente los primeros $\lfloor n/4 \rfloor$ residuos absolutos ordenados:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{\lfloor n/4 \rfloor} |\hat{\varepsilon}|^2_{(i)}}{\sum_{i=1}^{\lfloor n/4 \rfloor} \left[\Phi^{-1}\left(\frac{1+\tilde{p}_i}{2}\right)\right]^2}$$

donde $\tilde{p}_i = \frac{i}{n+1}$ y en la estimación inicial de escala se fija $\lfloor np \rfloor = \lfloor n/4 \rfloor$.

Paso 4. Calcular el vector de s_i^2 usando el promedio de los i primeros residuos cuadrados: Para cada $i \in \{1,\ldots,n\}$, se obtiene la varianza muestral acumulada de los i residuos más pequeños:

$$s_i^2 = \frac{1}{i}\sum_{j=1}^{i} |\hat{\varepsilon}|^2_{(j)}$$

Paso 5. Calcular el valor esperado de s_i^2 usando los percentiles de la distribución teórica normal plegada: Se determina la línea de base teórica $E(s_i^2)$ utilizando los cuantiles teóricos ξ_j escalados por $\hat{\sigma}$:

$$E(s_i^2) = \frac{1}{i}\sum_{j=1}^{i} \xi_j^2$$

donde $\xi_j = F^{-1}(\tilde{p}_j) = \hat{\sigma}\cdot\Phi^{-1}\left(\frac{1+\tilde{p}_j}{2}\right)$.

Paso 6. Calcular el cociente y tomar hasta el i-ésimo dato tal que su i-ésimo cociente sea el último que cumple ser menor que Q: Se evalúa la condición de tolerancia con el parámetro de sintonización Q ($Q = 1{,}28$) para definir el conjunto de observaciones válidas S:

$$S = \left\{ i \in \{1,\ldots,n\} : \frac{s_i^2}{E(s_i^2)} \leq Q \right\}$$

Paso 7. Rearmar el nuevo conjunto de entrenamiento solo con los x que tienen un residuo i asociado tal que es menor que el i del cociente tomado: Se asigna la función de ponderación $w_i = \psi(\hat{\varepsilon}_i)$ a cada observación para filtrar los *outliers*:

$$\psi(\hat{\varepsilon}_i) = \begin{cases} 1, & |\hat{\varepsilon}_i| \leq |\hat{\varepsilon}|_{(\lfloor n\hat{p} \rfloor)} \\ 0, & |\hat{\varepsilon}_i| > |\hat{\varepsilon}|_{(\lfloor n\hat{p} \rfloor)} \end{cases}$$

Paso 8. Calcular la proporción de limpios; si el cambio porcentual entre el anterior y este es menor que la tolerancia,

se considera convergencia y el método se detiene: Se actualiza la proporción estimada $\hat{p}^{(\text{Iter})} = \frac{|S|}{n}$ y se verifica si cumple el criterio de convergencia con respecto a la tolerancia $\tau = 10^{-4}$:

$$\frac{\left|\hat{p}^{(\text{Iter})} - \hat{p}^{(\text{Iter}-1)}\right|}{\hat{p}^{(\text{Iter})}} < \tau$$

Repetir hasta converger o hasta llegar al máximo de iteraciones ($\text{Iter}_{\text{máx}} = 20$).

Además, se plantean los siguientes modelos para comparar el rendimiento de BART (Árboles): Random Forest, Gradient Boosting, XGBoost y LightGBM, usados por Iban (2022); OLS, tomando inspiración del enfoque usado por Lozano-Gracia and Anselin (2012), y un predictor trivial de la mediana.

Otra característica clave por señalar es el enfoque hacia XAI (*Explainable Artificial Intelligence*), tal como lo plantea Iban (2022). Lograr explicar el modelo OLS es simple, pues la interpretación proviene de los propios coeficientes; sin embargo, la interpretación de los modelos de árbol requiere un método llamado SHAP (*SHapley Additive exPlanations*), que a grandes rasgos permite observar cómo cambia el impacto de una variable según su valor, cómo interactúa con otras características, cuáles variables son las más importantes en general y cómo influyen en el comportamiento global del modelo. Este método funciona para toda clase de modelos y se basa en la teoría de juegos adaptada al *machine learning*. Para estimar la contribución de una variable *i*, lo que se hace es:

1. **Coaliciones de variables:** Se forman todos los subconjuntos posibles de variables sin incluir a *i*.
2. **Contribución marginal:** Se evalúa cuánto cambia la predicción del modelo cuando se añade la variable *i* a cada una de esas coaliciones.
3. **Promedio ponderado:** Se calcula la media ponderada de todas las contribuciones marginales en todas las combinaciones posibles.

Su ecuación es:

$$\phi_i^{(j)} = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} \left[f(S \cup \{i\}) - f(S) \right]$$

Donde S es un subconjunto que no contiene a i, F representa todo el conjunto de variables y f simboliza el modelo a explicar. La ecuación anterior aplica solo para una observación; cuando se quiere estimar el comportamiento global (como lo hace el gráfico de tipo *beeswarm*), lo que se hace es calcular el ϕ_i para cada registro y después graficarlo.

Definición de parámetros prior e hiperparámetros En la siguiente tabla se muestran los parámetros que se plantearon para la iteración final del modelo BART(Atr) de Cao et al. (2024); se separa en 3 partes: los hiperparámetros propios de BART(Atr), los parámetros prior clásicos definidos por Chipman et al. (2010) y los parámetros propios de MCMC, necesarios para el diagnóstico de las cadenas. Cabe resaltar que se generó una clase llamada *BARTAtrRegressor* para implementar el método de Cao et al. (2024); esta clase se basa en un envoltorio que reentrena árboles BART de la librería stochtree desarrollada por Team (2024).

Parámetro	Valor	Justificación	Pertenece a
Recorte adaptativo			
`Q`	1,28	Umbral de $s_i^2/E(s_i^2)$ para definir S; elegido por Cao et al. (2024) por su balance entre precisión y costo.	BART(Atr)
`trim`	`True`	Activa el recorte duro: los pesos $\psi(\hat{\varepsilon}_i) \in \{0,1\}$ excluyen los atípicos.	BART(Atr)
`sigma_frac`	0,25	Estima σ^2 solo con el 25 % de residuos más pequeños ($n_p = n/4$) Cao et al. (2024).	BART(Atr)
`p_min`	0,5	Valor inicial $\hat{p}^{(0)} = 0{,}5$ y cota inferior: se recorta como máximo la mitad de los datos.	BART(Atr)
`tol`	10^{-4}	Tolerancia relativa τ sobre $\hat{p}$ para detener la iteración Cao et al. (2024).	BART(Atr)
`max_iter`	20	Máximo de iteraciones $\text{Iter}_{\text{máx}}$ del recorte Cao et al. (2024).	BART(Atr)
Priors de BART			
`num_trees`	50	Número de árboles m; valor usado por Cao et al. (2024).	BART
`alpha`	0,95	Prior de división $\alpha(1+d)^{-\beta}$; favorece árboles poco profundos Chipman et al. (2010).	BART
`beta`	2,0	Penaliza la profundidad para que cada árbol sea un aprendiz débil Chipman et al. (2010).	BART
`k`	2,0	Contrae los valores de las hojas μ para que ningún árbol domine el ajuste.	BART
`nu`	3,0	Grados de libertad de la prior χ^2-inversa de σ^2; prior poco informativa.	BART
`q`	0,9	Calibra la prior: $P(\sigma < \hat{\sigma}_{\text{OLS}}) = 0{,}9$.	BART
Muestreo MCMC			
`num_burnin`	3000	Calentamiento amplio para que las cadenas alcancen la estacionariedad antes de guardar muestras.	MCMC
`num_mcmc`	6000	Iteraciones posteriores al calentamiento para estimar la posterior de forma estable.	MCMC
`num_chains`	2	Cadenas independientes para diagnosticar la convergencia (p. ej. $\hat{R}$).	MCMC
`num_threads`	1	Ejecución secuencial para que los resultados sean reproducibles.	MCMC
`num_gfr`	2	Barridos *grow-from-root* (XBART) como arranque caliente del MCMC.	MCMC
`keep_every`	5	Adelgazamiento (1 de cada 5) para reducir la autocorrelación entre muestras.	MCMC
`random_state`	42	Semilla fija para que el experimento sea reproducible.	MCMC

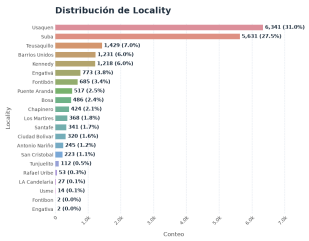
Tabla. 6. Hiperparámetros del modelo BART(Atr) adaptados de antecedentes literarios.

4. Análisis exploratorio de datos

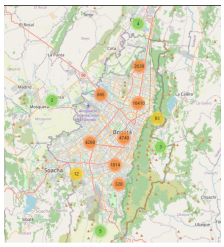
4.1 Hallazgos principales

4.1.1 Generales

Entre los hallazgos generales de la muestra se logra apreciar que la mayoría de viviendas están usadas; las localidades más comunes son Usaquén y Suba por un amplio margen, lo cual constituye un claro sesgo de la muestra a favor de las viviendas ubicadas en la parte norte de la ciudad. Adicionalmente, los estratos más comunes en la muestra recolectada son el 3 y el 4, y los tipos de vivienda más comunes son apartamentos y casas[4].



(a) Distribución de viviendas por localidad.



(b) Mapa de localización de inmuebles. Cada punto representa un clúster de viviendas que se desagrega individualmente al realizar zoom.

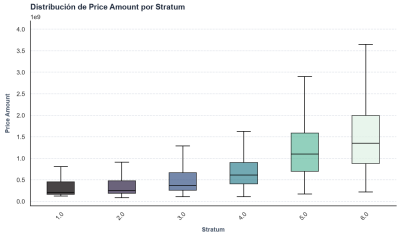
Fig. 5. Distribución geográfica y por localidad de la muestra de viviendas.

4.1.2 Asociaciones clave

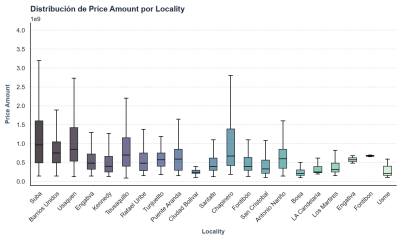
Al comparar la media de `price_amount` usando como variables segmentadoras de grupos a `property_type`, `stratum`, `age_bracket_code`, `publisher_type` y `city` con un nivel de significancia de $\alpha = 0,05$, en todas las variables se obtiene un p-valor menor a $0,05$, por lo que existen diferencias estadísticamente significativas en la distribución del precio entre al menos algunas de las categorías de `property_type`, `stratum`, `age_bracket_code`, `publisher_type` y `city`.

[4]Para más detalles sobre el EDA, consulte el repositorio de GitHub en `https://github.com/juanpablocarrillohortua/BART-trees-for-estimating-housing-prices-in-Bogot-`.

Esto se refleja mejor en la variable `stratum`, pues se observa cómo los precios crecen conforme el estrato aumenta, algo que coincide con lo planteado por Lozano-Gracia and Anselin (2012); además, las localidades que tienen mayores precios son Usaquén, Suba y Chapinero, mientras que aquellas de menores precios son Ciudad Bolívar y Bosa.



(a) Relación entre el estrato socioeconómico y el precio comercial de la vivienda.



(b) Distribución del precio comercial de la vivienda según la localidad.

Fig. 6. Relación del precio comercial de la vivienda frente al estrato socioeconómico y la localidad.

Esto configura una asociación que puede ser útil en los modelos a futuro. Bajo esta misma línea, se logra evidenciar a través de la matriz de correlación que las variables que más se asocian con el precio son el área construida y el número de baños (tal como plantea la hipótesis 1), seguidas por la cuota mensual de administración; esto sugiere qué variables podrían ser clave en la estimación del precio.

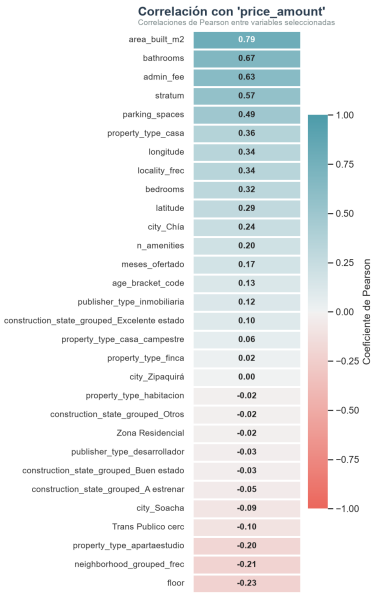


Fig. 7. Matriz de correlación de Pearson de las variables numéricas con el precio del inmueble.

5. Modelos

5.1 Pipeline

Antes del proceso de modelamiento se plantea un *pipeline* que, tomando como base la metodología típica del *machine learning* (incluida la partición del conjunto en prueba y entrenamiento Iban (2022)), utiliza un proceso de validación cruzada para la experimentación con varios modelos, tal como en Tapia et al. (2025). El *pipeline* que se define garantiza que no haya fuga de información en pasos críticos como en la imputación de faltantes con MICE (u otros estadísticos calculados de la muestra) o en la codificación con *frequency encoding*. Adicionalmente, el *pipeline* entrena el modelo usando `log_precios` y retorna los precios haciendo uso del objeto `TransformedTargetRegressor` de *scikit-learn*; esto permite tener una mejor estabilidad numérica y evita que el proceso de *trimming* sea extremadamente agresivo a la hora de cortarlos. Además, agrega un paso de selección de características basado en la información mutua de la característica y el logaritmo del precio, lo que permite obtener un conjunto más parsimonioso que solo conserva las n variables más informativas. Por lo tanto, la estructura del *pipeline* luce así:

5.2 Experimentos

Se corrió un experimento con cada uno de los modelos propuestos. Se debe destacar que el entrenamiento del método BART(Atr) (y BART estándar) fue supremamente lento (gastó aproximadamente 2,6 h por *fold*); esto se debe a que cada prueba de este constaba de 5 corridas enteras del objeto `BARTAtrRegressor` (provenientes de la validación cruzada) y cada una de estas ejecuciones conllevaba la imputación con métodos pesados como MICE más el entrenamiento de a lo sumo 20 modelos de tipo BART, dentro de los cuales se debía recorrer la cadena MCMC (un proceso que por sí solo ya es lento). Esto dio como resultado el mayor cuello de botella que se tuvo para experimentar, debido a que cada iteración de este modelo costaba aproximadamente 8 h. Adicionalmente, se entrenaron con la misma *pipeline* el OLS y los modelos propuestos por Iban (2022)[5], esto con el fin de comparar diferentes modelos y determinar cuál era la mejor opción.

Siguiendo la metodología orientada a la XAI Iban (2022), los modelos de árboles fueron interpretados con los mismos gráficos SHAP, esto con el fin de comparar sus comportamientos respecto a cómo usan las características. En las *pipelines* se seleccionan 6 o 18 variables, esto basado en el gráfico de información mutua que sugiere codos en dichos números de variables.



Fig. 8. Información mutua entre las características y el logaritmo del precio.

6. Presentación de resultados

6.1 Convergencia MCMC

En los experimentos bayesianos realizados, ya sea con BART o BART(Atr), las cadenas MCMC no convergieron; esto se ve con las métricas.

[5]No se ahonda en gran medida en la matemática o teoría de estos modelos, ya que solo fungen como comparaciones contra antecedentes en la literatura; a pesar de que no se han estudiado en la carrera en este punto, el docente permitió usarlos para comparar métricas.

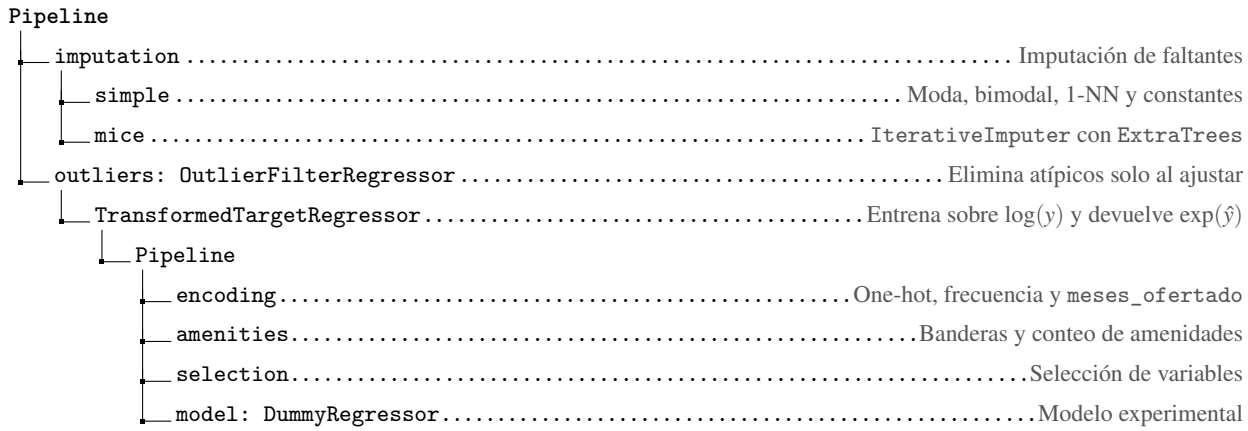


Fig. 9. Estructura del *pipeline* de preprocesamiento y modelamiento. La imputación se ajusta con todas las filas de entrenamiento. El filtro de atípicos solo elimina observaciones durante el ajuste; en la predicción todas las observaciones pasan al modelo. Además, el paso **OutlierFilterRegressor es independiente al corte de atípicos que BART(Atr) hace por sí mismo**.

Métrica	**BART (Atr)**	**BART default (18 var.)**	**BART default (6 var.)**
Configuración del muestreo			
Cadenas	2	2	2
Iteraciones (*draws*)	6000	4000	4000
Varianza del error σ^2			
Media posterior de σ^2	0.0305	0.0383	0.0517
$\hat{R}$	1.430	1.429	1.570
ESS *bulk*	4.08	4.27	3.48
ESS *tail*	12.00	9.36	9.00
MCSE de la media	0.00037	0.00039	0.00075
Predicciones $f(x)$			
$\hat{R}$ mediano	1.333	1.434	1.428
$\hat{R}$ máximo	2.423	2.569	2.568
% de observaciones con $\hat{R} > 1{,}01$	99.91	99.89	99.92
ESS *bulk* mediano	4.91	4.09	4.13
ESS *bulk* mínimo	2.44	2.38	2.39

Tabla. 7. Diagnósticos de convergencia MCMC por modelo (promedio de los 5 *folds*)

Vea cómo los modelos en general tienen un $\hat{R} > 1{,}01$, que es el umbral típico; además, al analizar individualmente el $\hat{R}$ de cada observación da como resultado que un poco menos del 100 % de las observaciones lo tienen por encima del umbral típico de 1,01. Adicionalmente a esto, el ESS (tanto en el centro de la posterior —*bulk*— como en sus extremos —*tail*—) en general es extremadamente bajo, pues por lo general se espera que este se encuentre por encima de 400. Este fallo en la convergencia de la posterior también es apreciable en el siguiente gráfico de traza, donde se hace evidente que el fallo más drástico del procedimiento se dio en la convergencia para las predicciones, ya que vea que en los paneles 2 a 4 se aprecia cómo las densidades parecen «contradecirse»; adicionalmente, las curvas de las predicciones nunca llegan a mezclarse, es decir, las cadenas no están convergiendo a la misma posterior. Si bien este problema es menos marcado para la varianza, se sigue apreciando que las dos cadenas bajan de forma sostenida durante todas las iteraciones, de unos 0,0275 a unos 0,0265. Eso significa que las cadenas no son estacionarias: todavía no llega a la posterior, y el *burn-in*

fue insuficiente a pesar de ser de 3000 iteraciones.

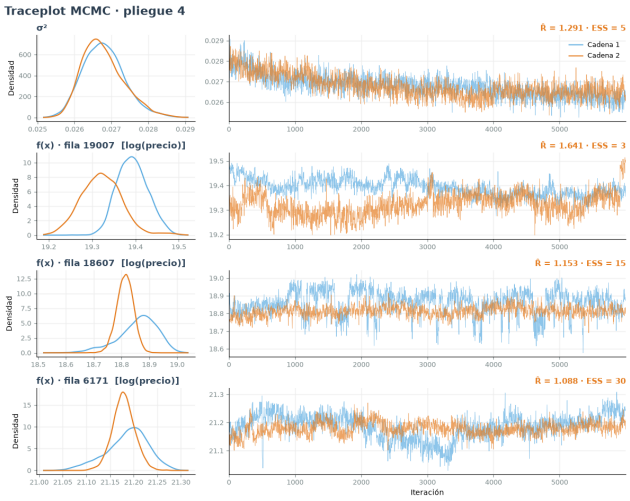


Fig. 10. Gráfico de traza y densidades para evaluar la convergencia MCMC del modelo.

Este fracaso en la convergencia invalida los intervalos de credibilidad para las predicciones y para los valores SHAP; no obstante, no invalida las métricas de CV que se mostrarán a continuación, es decir, el modelo presenta un buen rendimiento predictivo de manera empírica a pesar de la divergencia de la cadena.

6.2 Métricas de cross validation y de test

A continuación, se presentan las métricas promedio que tuvo cada modelo en sus *folds*. Se agregan tres métricas que no son usuales, propuestas por Lozano-Gracia and Anselin (2012): predicciones dentro del 10 %, que es la proporción de inmuebles estimados dentro del $\pm 10\,\%$ del valor real y evalúa la precisión dentro del rango óptimo de negociación comercial; predicciones dentro del 20 %, que representa la proporción de inmuebles estimados dentro del $\pm 20\,\%$ del valor real y mide la capacidad del modelo para mantener los errores dentro de un rango de tolerancia comercialmente aceptable para sistemas automáticos de tasación; y el porcentaje de sobrepredicción, que mide el porcentaje de inmuebles donde la predicción supera el valor real ($\hat{y} > y$). Un porcentaje elevado ($> 50\,\%$) indica un sesgo positivo, lo que incrementa el riesgo de estancar los inmuebles en portales inmobiliarios al superar la disposición a pagar; el ideal es que esté cerca del 50 %, ya que si es menor que este, el modelo estaría subprediciendo, lo que llevaría a vender los inmuebles por debajo de su valor real.

El mejor modelo en CV fue XGBoost; no obstante, los demás modelos de árboles rinden de manera similar. Incluso se ve que XGBoost tiene métricas más estables, pues en general sus métricas tienen una menor desviación estándar. A continuación, se presentan las métricas de test de XGBoost con 18 variables y de BART(Atr) para la comparación final.

En el conjunto de prueba (test) se evaluó el mejor modelo (XGBoost) y también el modelo que se quiere implementar (BART(Atr)), y se obtuvieron los siguientes resultados.

Se evidencia cómo en general XGBoost es mejor que BART(Atr); no obstante, la diferencia en la sobrepredicción y el R^2 no es especialmente alta. La diferencia más crítica radica en el cambio del MAE y el RMSE, ya que para agencias pequeñas una diferencia de 11 millones puede considerarse crítica. Adicionalmente, las métricas definidas por Lozano-Gracia and Anselin (2012) son relativamente similares, donde XGBoost supera a BART por 4,5 y 3,6 puntos porcentuales en Acc_{10} y Acc_{20}, respectivamente. La sobrepredicción es muy similar en ambos, por lo que ninguno tiende sistemáticamente a sobreestimar o subestimar los precios. Asimismo, los dos modelos presentan métricas similares en validación cruzada y en prueba, lo cual indica que los modelos no sobreajustaron y tienen una buena capacidad de generalización. La ventaja prospectiva que podría tener BART (Atr) —los intervalos de credibilidad en las predicciones y en los valores SHAP— se pierde, ya que al usar todo el conjunto de entrenamiento la cadena MCMC no convergió y mantuvo un comportamiento similar al obtenido en la validación cruzada.

6.3 Gráficos SHAP

A continuación, se muestran los gráficos SHAP, tomados del enfoque XAI propuesto por Iban (2022); se comparará el gráfico de XGBoost con el de BART(Atr), esto ya que la no convergencia de la cadena también impacta en lo fiables que son los valores SHAP de BART(Atr).

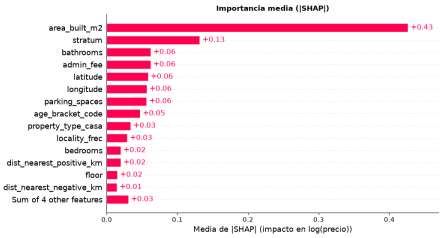
Modelo	**Var.**	**RMSE (COP)**		**MAE (COP)**		**MAPE (%)**		R^2		**Acc$_{10}$ (%)**		**Acc$_{20}$ (%)**		**Sobrepred. (%)**	
		Media	Desv.	Media	Desv.	Media	Desv.	Media	Desv.	Media	Desv.	Media	Desv.	Media	Desv.
Línea base (mediana)	–	860.764.700	15.358.030	564.370.900	8.042.467	72,42	1,54	−0,1169	0,0126	10,19	0,63	19,41	0,94	49,07	1,23
OLS	6	450.148.500	22.466.080	255.182.700	10.607.920	27,95	1,60	0,6941	0,0279	28,20	0,31	52,44	0,40	53,64	1,59
OLS	18	412.424.100	13.250.940	224.527.200	6.286.938	21,74	0,75	0,7435	0,0132	33,55	0,83	60,40	0,63	53,96	1,30
BART	6	399.706.100	21.516.210	212.605.000	13.809.130	21,58	1,70	0,7588	0,0227	36,20	0,94	63,40	1,45	53,03	1,39
BART	18	348.971.300	11.243.000	179.847.900	9.012.763	17,24	0,73	0,8164	0,0080	41,99	0,92	70,08	0,94	51,79	1,06
BART (Atr)	18	345.012.400	13.739.430	176.700.600	5.714.384	16,84	0,84	0,8205	0,0105	43,06	0,94	71,33	0,53	51,36	1,36
Random Forest	6	380.172.200	17.425.350	197.727.200	11.035.610	20,27	1,62	0,7821	0,0148	40,20	0,87	66,30	1,09	53,67	1,57
Random Forest	18	356.726.500	11.818.690	175.641.000	6.219.628	17,00	0,70	0,8082	0,0083	44,75	0,99	70,81	0,76	52,85	1,34
XGBoost	6	372.407.600	20.139.170	192.213.800	12.469.830	19,34	1,84	0,7907	0,0186	41,54	1,21	68,40	1,43	52,11	1,72
XGBoost	18	338.792.100	11.991.730	**165.940.100**	5.095.882	**15,76**	0,63	0,8269	0,0096	**46,39**	1,43	**73,71**	0,68	51,49	1,08
LightGBM	6	374.104.900	22.973.780	193.200.300	13.983.610	19,34	2,04	0,7888	0,0215	41,93	0,95	68,33	1,22	51,96	1,70
LightGBM	18	**336.028.000**	12.067.740	167.233.100	6.888.629	15,83	0,62	**0,8298**	0,0084	45,86	1,31	73,16	0,71	51,56	1,01

Tabla. 8. Métricas de validación cruzada por modelo (media y desviación estándar entre los 5 *folds*). En negrita, el mejor valor de cada métrica. Acc$_{10}$ y Acc$_{20}$: porcentaje de predicciones dentro de ± 10 % y ± 20 % del precio pedido; Sobrepred.: porcentaje de predicciones por encima del precio pedido.

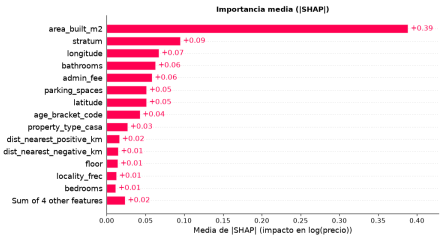
Métrica	BART (Atr)	XGBoost	Diferencia	Mejor
RMSE (COP)	354.621.554	**342.646.583**	11.974.970	XGBoost
MAE (COP)	174.921.186	**163.743.451**	11.177.734	XGBoost
MAPE (%)	16,8	**15,6**	1,2	XGBoost
R^2	0,809	**0,822**	−0,013	XGBoost
Acc_{10} (%)	42,186	**46,748**	−4,562	XGBoost
Acc_{20} (%)	70,799	**74,435**	−3,636	XGBoost
Sobrepredicción (%)	49,684	**50,294**	−0,610	XGBoost

Tabla. 9. Comparación del desempeño predictivo entre BART (Atr) y XGBoost en el conjunto de prueba. La diferencia se calcula como BART (Atr) menos XGBoost.

6.3.1 Feature Importance Plot



(a) Importancia global de características (SHAP) para el modelo BART(Atr).

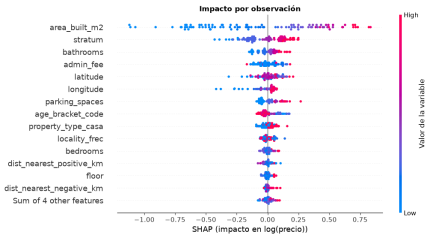


(b) Importancia global de características (SHAP) para el modelo XGBoost.

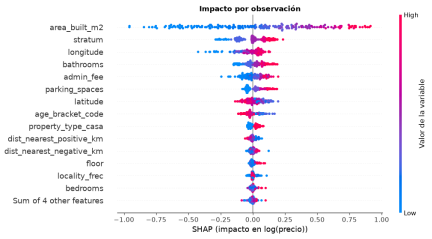
Fig. 11. Comparación de la importancia de características basada en valores SHAP entre los modelos BART y XGBoost.

Ambos modelos coinciden en que la variable de mayor asociación (por un amplio margen) es el área construida del inmueble, seguida por el estrato; esto confirma las hipótesis 1 y 5. En las demás características, por lo general están de acuerdo respecto a que son importantes, solo que cambiando el ordenamiento entre características. Adicionalmente, ambos modelos le dan una importancia considerable a características geográficas del inmueble, por ejemplo, sus coordenadas o la distancia a los landmarks (especialmente los positivos).

6.3.2 Beeswarm Plot



(a) Gráfico de tipo *beeswarm* de valores SHAP para el modelo BART.



(b) Gráfico de tipo *beeswarm* de valores SHAP para el modelo XGBoost.

Fig. 12. Comparación de los impactos individuales de las características (*beeswarm* SHAP) entre los modelos BART y XGBoost.

Ambos modelos coinciden en que, conforme el metraje del inmueble es mayor, se asocia a precios más altos (la variable tendrá un efecto de agregación mayor en el resultado); lo mismo ocurre con el estrato, baños y demás características físicas del inmueble. Respecto al componente geoespacial, ambos modelos coinciden en que una mayor distancia a los *landmarks* negativos se asocia con un impacto positivo sobre el precio, mientras que una baja distancia a *landmarks* positivos se asocia con un efecto positivo sobre el precio. Un resultado interesante es que, con valores de longitud altos, los inmuebles tienden a elevar su precio, lo cual se explica

ya que valores de longitud más grandes (más cercanos a $0°$, dado que la longitud de Bogotá ronda los $-74°$) se asocian a localizaciones más cerca del oriente; es decir, estar cerca de los cerros orientales constituye un factor que puede potenciar el precio.

7. Conclusión y discusión de resultados

En general, los objetivos se cumplieron satisfactoriamente: se logró generar un sistema AVM con alta capacidad explicativa mediante XAI; además, se logró superar con creces el rendimiento de la propuesta de Lozano-Gracia and Anselin (2012) para Bogotá, incluso con el modelo BART (Árboles). Adicionalmente, aunque las métricas de Iban (2022) sean superiores, se considera una ganancia que el modelo BART propuesto se haya acercado significativamente, teniendo en cuenta que el presente proyecto considera toda la ciudad y no solo un sector de esta.

7.1 Conclusiones y trabajo futuro

Se logró interpretar el modelo mediante métodos SHAP y se confirmaron las hipótesis 1, 2, 3 y 5. La variable que indicaba la cercanía al transporte público no fue considerada en la selección final, por lo que la hipótesis 4 no se logró demostrar.

Dado que la cadena MCMC no convergió (a pesar del extenso tiempo de entrenamiento), no se logró cumplir el objetivo específico relacionado con la inferencia bayesiana completa; a pesar de esto, se logró proponer una primera iteración de esta clase de modelos que se acerca al rendimiento predictivo de arquitecturas ya consolidadas en la literatura dentro de un contexto urbano real. Por lo tanto, los trabajos futuros se centrarán en experimentar con distintas distribuciones a priori o en modificar el conjunto de entradas mediante ingeniería de características avanzada, esto con el fin de alcanzar la convergencia de la cadena MCMC y aprovechar con total rigor las propiedades bayesianas del modelo. Además, cabe recordar que una limitación clave del proyecto (y en general en mercados como Bogotá) es la falta de datos sobre los precios de venta, lo cual obliga a utilizar los precios pedidos, tal como lo hace este artículo y otros autores.

Métrica	**BART (Atr)** *(prueba)*	**Lozano-Gracia and Anselin (2012)** *6-SMK: submercados por estrato*	**Iban (2022)** *XGBoost*
RMSE	354.621.554 COP		146.837 TL
MAE (COP)	174.921.186		
MAPE (%)	16,8	31.42	9,04
R^2	0,809		0,8733
Acc_{10} (%)	42,19	26,40	
Acc_{20} (%)	70,80	49,32	
Sobrepredicción (%)	49,68	60,59	

Tabla. 10. Comparación del desempeño de BART (Atr) en el conjunto de prueba con los mejores modelos reportados en la literatura. Las celdas vacías corresponden a métricas no reportadas por los autores. El RMSE de Iban (2022) está expresado en liras turcas (TL) y no es comparable en magnitud con el de este trabajo.

BIBLIOGRAFÍA

Cao, T., Wu, J., and Wang, Y.-G. (2024). An adaptive trimming approach to bayesian additive regression trees. *Complex Intelligent Systems*, 10(5):6493–6509.

Chang, J. S. (2006). Models of the relationship between transport and land-use: A review. *Transport Reviews*, 26(3):325–350.

Chipman, H. A., George, E. I., and McCulloch, R. E. (2010). Bart: Bayesian additive regression trees. *The Annals of Applied Statistics*, 4(1):266–298.

Diaz-Garayua, J. R. (2009). Neighborhood characteristics and housing values within the san juan, msa, puerto rico. *Southeastern Geographer*, 49(4):376–393.

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., et al. (2020). Array programming with numpy. *Nature*, 585(7825):357–362.

Hunter, J. D. (2007). Matplotlib: A 2d graphics environment. *Computing in Science Engineering*, 9(3):90–95.

Iban, M. C. (2022). An explainable model for the mass appraisal of residences: The application of tree-based machine learning algorithms and interpretation of value determinants. *Habitat International*, 128:102660.

Kumar, R., Carroll, C., Hartikainen, A., and Martin, O. (2019). Arviz a unified library for exploratory analysis of bayesian models in python. *Journal of Open Source Software*, 4(33):1143.

Loret de Mola, U., Ladd, B., Duarte, S., Borchard, N., Anaya La Rosa, R., and Zutta, B. (2017). On the use of hedonic price indices to understand ecosystem service provision from urban green space in five latin american megacities. *Forests*, 8(12):478.

Lozano-Gracia, N. and Anselin, L. (2012). Is the price right?: Assessing estimates of cadastral values for bogota, colombia. *Regional Science Policy Practice*, 4(1):1–14.

Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, volume 30, pages 4765–4774.

McKinney, W. (2010). Data structures for statistical computing in python. In *Proceedings of the 9th Python in Science Conference*, volume 445, pages 56–61.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., et al. (2011). Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830.

Tapia, J., Chavez-Garzon, N., Pezoa, R., Suarez-Aldunate, P., and Pilleux, M. (2025). Comparing automated valuation models for real estate assessment in the santiago metropolitan region: A study on machine learning algorithms and hedonic pricing with spatial adjustments. *PLoS ONE*, 20(3):e0318701.

Team, S. D. (2024). Stochtree: C++ and python implementations of bayesian additive regression trees and stochastic tree ensembles.

Villada-Medina, H. D., Diez-Echavarria, L., Lopez-Aristizabal, D. C., Castaneda, J. C., and Velasquez-Perez, I. C. (2023). Efecto de los centros comerciales en el precio de la vivienda: el caso de medellin. *Anales de Geografia de la Universidad Complutense*, 43(2):555–573.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., et al. (2020). Scipy 1.0: Fundamental algorithms for scientific computing in python. *Nature Methods*, 17(3):261–272.

Waskom, M. L. (2021). Seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60):3021.