Hacia un sistema de valuación masiva con BART para la vivienda de Bogotá y alrededores

BART con recorte adaptativo (Cao et al., 2024) frente a OLS, Random Forest, XGBoost y LightGBM

Juan Pablo Carrillo Hortua · Julian David Rodriguez Ramirez · Samuel Acosta Morales

Estadística Bayesiana · Docente: Jairo Mora · Departamento de Matemáticas, Ciencia de Datos · Universidad Externado de Colombia

Código y notebooks en GitHub

1 Planteamiento y formulación

Problema. En Colombia es difícil acceder a precios reales de venta, y los oficiales son poco confiables por subdeclaración fiscal (Lozano-Gracia y Anselin, 2012). Como en Turquía (Iban, 2022), se usan *precios pedidos* de portales web.

PREGUNTA DE INVESTIGACIÓN

¿Qué factores de ubicación (localidad/municipio, estrato) y de características físicas (área, habitaciones, baños, antigüedad) se asocian con el precio pedido de la vivienda usada en Bogotá, Soacha, Chía y Zipaquirá, y cuáles son los mejores para predecirlo?

Objetivo general. Crear un prototipo de sistema de valuación masiva (MAS) para los precios pedidos en Bogotá y alrededores.

OBJETIVOS ESPECÍFICOS

1. Superar las métricas de Lozano-Gracia y Anselin (2012): MAPE 29,99 %, sobrepredicción 60,59 %, ±10 % = 17,06 %.
2. Explicar el modelo con métodos XAI como SHAP (Iban, 2022).
3. Cadenas MCMC que converjan, para dar intervalos de credibilidad.

2 Revisión de literatura

Lozano-Gracia y Anselin (2012)
Regional Science Policy & Practice

Evalúan los avalúos catastrales de Bogotá con modelos hedónicos.

En este estudio: sus métricas son la meta; su enfoque justifica usar variables SIG.

Iban (2022)
Habitat International

Avalúo masivo con RF, GBM, XGBoost, LightGBM y XAI en Turquía, sin datos de transacción.

En este estudio: justifica los precios pedidos, los modelos rivales y las métricas.

Cao, Wu y Wang (2024)
Complex & Intelligent Systems

Proponen BART(Atr): recorta atípicos de forma adaptativa. Solo se probó en simulaciones y Boston Housing (506 casas).

En este estudio: es el algoritmo central, con sus hiperparámetros.

Chang (2006)
La localización es heterogénea e indivisible; los modelos de subasta no predicen directamente.

Tapia et al. (2025)
Precios fijados de forma informal en Santiago; comparan LightGBM y SAR.

Villada-Medina et al. (2023)
Un centro comercial a ≤ 0,5 km eleva el precio entre 3,59 % y 7,39 % en Medellín.

Loret de Mola et al. (2017)
Las áreas verdes elevan los precios en cinco megaciudades, incluida Bogotá.

VACÍO
En Web of Science no encontramos aplicaciones de BART(Atr) a un mercado inmobiliario real ni sistemas MAS bayesianos para Bogotá con datos actuales.

ESTE ESTUDIO
Aplica BART(Atr) a 22.139 avisos de FincaRaíz con distancias a *landmarks*, frente a OLS y ensambles de árboles.

3 Enfoque analítico y metodología

FASE 1 — Captura
Scraper propio; cobertura del 91,3 %.
31.252 avisos

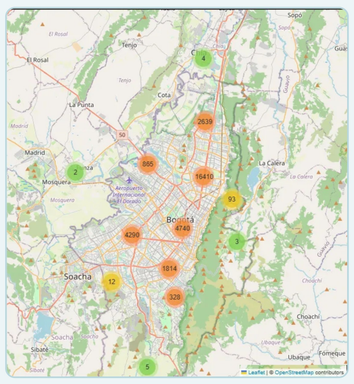
FASE 2 — Depuración
Vivienda en COP, $30 M–$20.000 M, sin atípicos por localidad.
22.139 avisos

FASE 3 — Variables SIG
Distancia al *landmark* positivo y al negativo más cercano.
61 + 59 landmarks

FASE 4 — Pipeline
Imputación, atípicos, log-precio y selección, reaprendidos en cada fold.
18 de 32 variables

FASE 5 — Modelos
OLS, RF, XGBoost, LightGBM, BART y BART(Atr); 80/20 y CV de 5 folds.
17.711 / 4.428

Datos: ubicación e imputación



31.252
avisos descargados de FincaRaíz

22.139
avisos tras depurar (70,8 %)

Fig. 1. Avisos descargados (antes de depurar), agrupados por cercanía. Mapa base: © OpenStreetMap contributors.

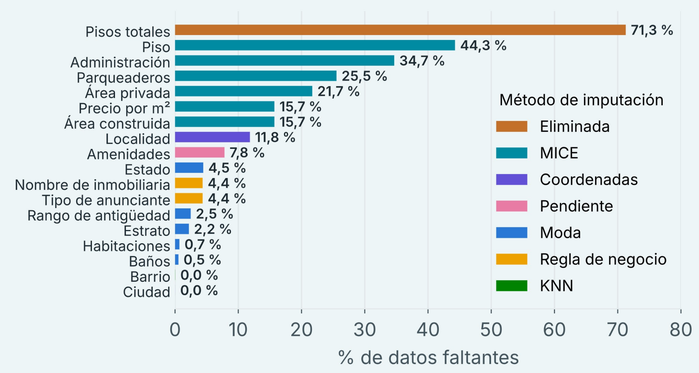
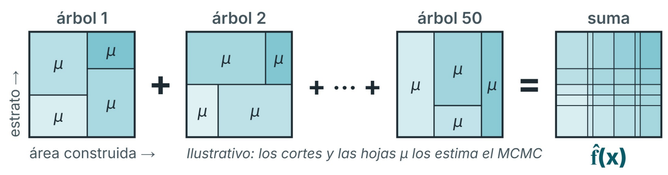


Fig. 2. Faltantes por columna y método de imputación (*data_cleaning.ipynb*).

BART: suma de árboles con priors (Chipman et al., 2010)



Cada árbol lotea el espacio; BART suma 50 loteos.

BART(Atr): recorte adaptativo (Cao et al., 2024)

1. **Ajustar BART** y calcular los residuos $\hat{\varepsilon}_i = y_i - \hat{f}(x_i)$.
2. $\hat{\sigma}^2$ **robusto** con el 25 % de residuos más pequeños frente a los cuantiles de la normal plegada.
3. $\hat{\mathbf{p}}$ = proporción de posiciones con $s_i^2/E(s_i^2) \le Q = 1{,}28$ (normalidad asintótica de s_i^2).
4. **Recortar** los residuos mayores que el de rango $\lfloor n\hat{p} \rfloor$ y reajustar BART sin ellos.
5. **Repetir 2–4** hasta $|\hat{p}_t - \hat{p}_{t-1}| / \hat{p}_t < 10^{-4}$ o 20 iteraciones.

m = 50 · α = 0,95, β = 2 · k = 2 · ν = 3, q = 0,90 · Q = 1,28
2 cadenas × 6.000 draws · burn-in 3.000, thin 5 · *stochtree*

Selección de variables

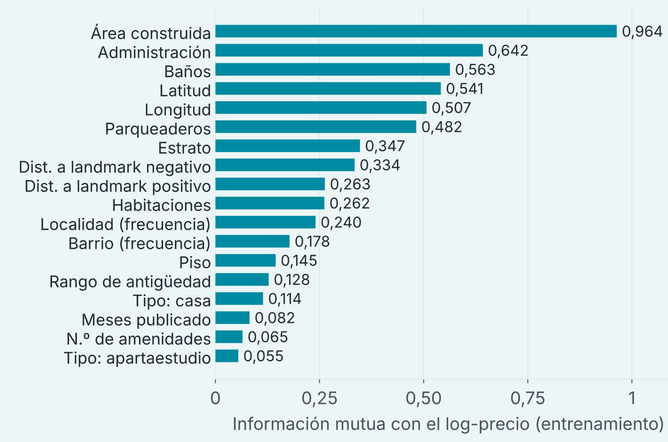


Fig. 3. Las 18 variables de mayor información mutua, de 32 candidatas. SelectKBest las elige y se reaprende en cada fold.

4 Resultados e implicaciones

OBJETIVO 1: BART(ATR) EN PRUEBA (4.428 AVISOS) FRENTE A LA META DE LOZANO-GRACIA Y ANSELIN (2012)

MAPE
16,8 %
Meta: **29,99 %** · menor es mejor

Dentro de ±10 %
42,2 %
Meta: **17,06 %** · mayor es mejor

Sobrepredicción
49,7 %
Meta: **60,59 %** · menor es mejor

ESTADO DE LOS OBJETIVOS

- **1. Cumplido:** los 11 modelos superan las tres metas.
- **2. Cumplido:** interpretación de variables con SHAP.
- **3. No logrado:** las cadenas no convergieron ($\hat{R} \approx 1{,}43$ en σ^2), sin intervalos de credibilidad.

Precisión fuera de muestra

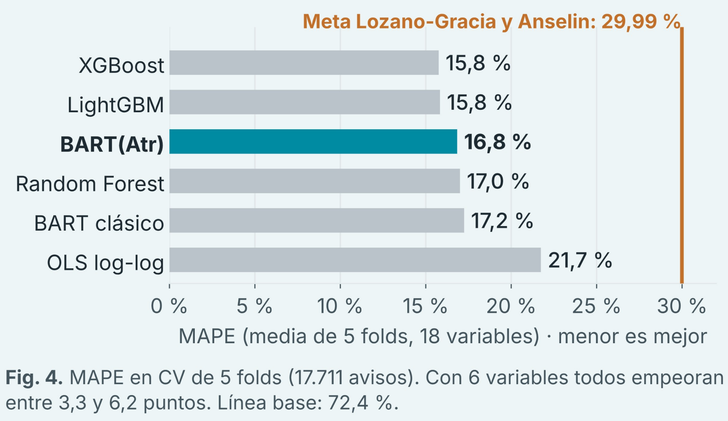


Fig. 4. MAPE en CV de 5 folds (17.711 avisos). Con 6 variables todos empeoran entre 3,3 y 6,2 puntos. Línea base: 72,4 %.

El recorte baja el MAPE de BART de 17,2 % a 16,8 % (mejor en 4 de 5 folds; R^2 = 0,821). En prueba: MAPE 16,8 % y R^2 = 0,809, frente a 15,6 % de XGBoost; CV y prueba coinciden.

¿Qué variables pesan más en la predicción? (SHAP)

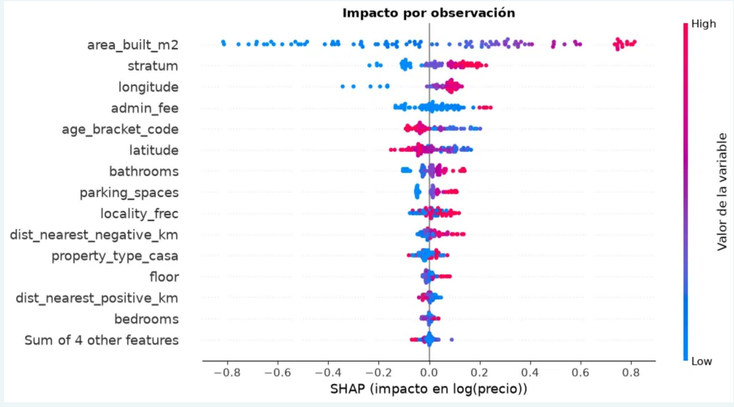


Fig. 5. Impacto SHAP en el log-precio: cada punto es un inmueble y el color, el valor de la variable. Área construida y estrato pesan más.

Las cadenas MCMC de BART no convergieron ($\hat{R} \approx 1{,}43$): los intervalos de credibilidad de las predicciones y de SHAP no son válidos, aunque las métricas de CV y de prueba sí lo son.

Convergencia MCMC y costo

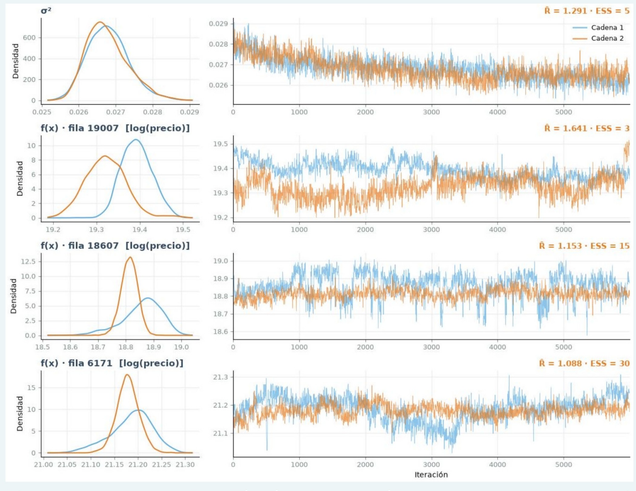


Fig. 6. Traceplot de BART(Atr), pliegue 4 (2 cadenas × 6.000 draws). Las cadenas no se mezclan bien y ningún panel cumple $\hat{R} < 1{,}01$.

> 99,8 % de las predicciones f(x) con $\hat{R} > 1{,}01$, en todos los folds

2,6 h por fold (BART clásico: 2,5 min; XGBoost: 38 s)

HALLAZGO CLAVE

Un MAS con precios pedidos supera con creces las metas de Lozano-Gracia y Anselin para Bogotá. BART(Atr) se acerca a XGBoost en prueba, pero su ventaja propia, la incertidumbre, exige cadenas que converjan.

Implicaciones

- **MAS:** con datos web se puede valuar sin precios de transacción (Iban, 2022).
- **Método:** el recorte de Cao et al. funciona fuera de Boston; un buen MAPE no garantiza una posterior válida.

Limitaciones y trabajo futuro

- Precio pedido ≠ de cierre; muestra no probabilística; meta de otra base.
- Correr más cadenas o reparametrizar hasta converger, y validar con CV espacial.

Referencias. Cao, T., Wu, J. y Wang, Y.-G. (2024). *Complex Intell. Syst., 10*(5), 6805–6823. doi:10.1007/s40747-024-01516-x · Chang, J. S. (2006). *Transp. Rev., 26*(3), 325–350. doi:10.1080/01441640500468432 · Chipman, H. A., George, E. I. y McCulloch, R. E. (2010). *Ann. Appl. Stat., 4*(1), 266–298. doi:10.1214/09-AOAS285 · Iban, M. C. (2022). *Habitat Int., 128*, 102660. doi:10.1016/j.habitatint.2022.102660 · Loret de Mola, U. et al. (2017). *Forests, 8*(12), 478. doi:10.3390/f8120478 · Lozano-Gracia, N. y Anselin, L. (2012). *Reg. Sci. Policy Pract., 4*(4), 495–508. doi:10.1111/j.1757-7802.2012.01062.x · Lundberg, S. M. y Lee, S.-I. (2017). *NeurIPS, 30*, 4765–4774. arXiv:1705.07874 · Tapia, J. et al. (2025). *PLOS ONE, 20*(3), e0318701. doi:10.1371/journal.pone.0318701 · Villada-Medina, H. D. et al. (2023). *An. Geogr. Univ. Complut., 43*(2), 555–573. doi:10.5209/aguc.90588